TEMPLATE PARA ENTREGA DO PROJETO DA DISCIPLINA
Ciência de Dados e Inteligência Artificial
Fase 1

Nome do estudante: Cecília Bobsin do Canto

Síntese do conjunto de dados como apresentado na sua origem:

Apresente uma breve descrição, acerca do conjunto de dados escolhido, indicando as informações contidas nos dados selecionados. É importante, ao apresentar sua síntese, que você inclua elementos que permitam compreender o significado e a aplicação dos dados escolhidos. (Mínimo de 2 parágrafos)

O conjunto de dados selecionados foi retirado do portal de dados abertos de Porto Alegre (https://dadosabertos.poa.br/dataset/iptu) e referem-se aos dados do IPTU de 2025. A planilha baixada traz diversas informações úteis para análise, tais como o bairro, cep, destinação do uso do imóvel, a metragem do imóvel, o valor venal, o valor da alíquota do imposto, o valor do imposto, o valor da Taxa de Coleta de Lixo (TCL), dentre outros.

Foram consideradas apenas 16 das 32 colunas existentes no arquivo original. As colunas foram escolhidas de acordo com a seguinte situação hipotética: Uma empresa deseja construir um empreendimento imobiliário num terreno baldio de uma determinada rua de Porto Alegre, sabendo apenas informações de localização, metragem e valor, objetiva-se prever o valor de IPTU correspondente a cada apartamento, para que na venda dos imóveis ainda na planta se possa utilizar essa informação para agregar mais valor à experiência daquele cliente que desejar fazer um planejamento prévio dos recursos a serem dispendidos na compra de um imóvel.

Quantidade de linhas e colunas do conjunto de dados:

Descreva apenas a quantidade de linhas e de colunas selecionadas.

Para análise foi feito um recorte da planilha original (.csv), considerando-se apenas 16 colunas e 73.779 linhas (excetuando o cabeçalho). Como a tabela original passava de 800 mil linhas, foram removidas as colunas A (que refere-se ao ano de exercício do IPTU – 2025), F, G, H e I (que referem-se ao número do LOTE, do BLOCO, nome e código do LOGRADOURO onde se localiza o imóvel), L (que refere-se ao tipo de unidade e que continha muitos valores em branco), M, N, O, P e Q (que referem-se ao número da unidade, pavimento, nível, complemento e uso do imóvel, também com muitos valores em branco), S e T (que referem-se ao número de identificação da destinação do imóvel e da zona), AD e AF (que referem-se ao valor do IPTU em UFM e da TAXA DE COLETA DE LIXO em UFM). Por fim, foram filtrados apenas os registros cuja finalidade (coluna R) era igual a “APARTAMENTO”, posteriormente esta coluna foi apagada, restando, para fins de análise, as seguintes colunas:

Nº Divisão Fiscal: O município de Poa é dividido em 3 divisões, para fins tributários, representam o grau de valorização da localização do imóvel.
Bairro: Bairro de porto alegre onde se situa o imóvel objeto do imposto.
Nº Setor: O setor fiscal é uma subdivisão da divisão fiscal.
Nº Quarteirão: Subdivisão do setor. Em um determinado setor há vários quarteirões.
CEP: Código criado pelos Correios para identificar uma determinada localização.

Nº do endereço: Nº do endereço do imóvel situado numa determinada rua, avenida ou logradouro.

Metragem área testada: Comprimento da frente do terreno, em metros

Metragem área real: Área real cadastrada do imóvel, em m²

Metragem área construída: Área construída total, em m²

Metragem área corrigida: É a área utilizada pela Prefeitura para o cálculo do valor venal do imóvel e do IPTU, em m².

Valor venal do terreno:O valor venal do terreno é o valor atribuído pela Prefeitura ao terreno onde se situa o imóvel, para fins tributários.

Valor venal das construções: Valor estimado pela Prefeitura para as construções existentes no imóvel.

Valor venal do imóvel: Valor venal total do imóvel. Valor avaliado pela Prefeitura.

Valor da alíquota: Percentual aplicado à base de cálculo do IPTU para determinar o imposto.

Valor da Taxa de Coleta de Lixo: Valor da TCL, cobrada pelo serviço público de coleta e destinação dos resíduos.

Valor do imposto (coluna alvo): Valor do IPTU para determinado imóvel.

Escolha pelo menos 10 colunas totalmente preenchidas (as mais importantes) e, para cada coluna (inclusive para a coluna alvo):

- Qual o nome e o que representa?
- Qual o tipo de dados? Nominal/Ordinal/Numérico/Data e/ou hora?
- Quais são os valores considerados válidos?
- Quantos valores distintos aparecem na coluna?
- Qual o menor e o maior valor, e qual a moda?
- Os valores da coluna são numéricos? Qual a média e qual o desvio-padrão? Qual a mediana?

Você pode apresentar essas informações da maneira como entender mais conveniente, como por exemplo em uma tabela, parágrafos, etc. É importante que sejam inseridas as imagens e as evidências do passo a passo realizado na atividade.

ATENÇÃO: Apresente imagens evidenciando os cálculos (Ex: print das fórmulas do Excel, Orange, script em python, etc). Os trabalhos que não apresentarem imagens receberam um desconto na nota.

Anexado ao final deste template. Não foram identificados valores inválidos, após realizados os filtros anteriormente descritos.

Descrição da coluna alvo e potenciais aplicações:

Informe qual a coluna alvo escolhida e descreva possíveis aplicações usando aprendizado de máquina que possam utilizá-la.

A coluna alvo escolhida é a de Valor do IPTU. Prever o valor do iptu nas diferentes regiões de Porto Alegre pode ser uma variável importante pra empresas que queiram construir e vender imóveis na planta. Também pode ser importante para um estudo que queira detectar discrepâncias entre os valores oficialmente cobrados num determinado bairro, por exemplo.

Link para acesso aos dados selecionados:

Inclua aqui o link para o conjunto de dados escolhido. No caso de ter sido feito um recorte/amostragem do conjunto original, documentar quais foram os passos feitos para produzir o recorte.

ATENÇÃO: O conjunto de dados do link deve estar PRONTO para ser carregado no Orange.

https://github.com/ceciliabobsin/ciencia_de_dados

O documento a ser carregado no Orange é o arquivo csv intitulado iptu_recorte_fase1.csv. Os passos realizados para efetuar o recorte foram documentados na segunda questão. Os documentos constantes no link são:

1. Arquivo original da base de dados do IPTU 2025 (https://dadosabertos.poa.br/dataset/iptu), intitulado iptu_2025_arquivo_original.zip.

2. Arquivo csv com um recorte dos dados originais, intitulado iptu_recorte_fase1.csv.

3. Arquivo txt com o recorte dos dados, para carga no python, para cálculos (média, mediana, desvio padrão, etc) dos valores de cada coluna/variável, intitulado iptu_recorte_fase1.txt.

4. Programa em python para leitura do arquivo e cálculo da moda, mediana, média, mínimo, máximo, desvio padrão, quantidade de valores distintos, conforme solicitado no Template.

5. Planilha de informações das variáveis/colunas consideradas, intitulada “planilha de informações das variáveis.xlsx”.

6. Carga dos dados no Orange, intitulada pre_processamento_iptu_fase1.ows.

Nome da coluna	O que representa	Tipo de dado	Qtd valores considerados válidos	Qtd valores distintos	Menor valor	Maior valor	Média	Mediana	Moda	Desvio Padrão
Nº Divisão Fiscal	O município de Poa é dividido em 3 divisões, para fins tributários, representam o grau de valorização da localização do imóvel.	Categórico	73.779	3					1	
Bairro	Bairro de porto alegre onde se situa o imóvel objeto do imposto.	Categórico	73.779	86					PETROPOLIS	
Nº Setor	O setor fiscal é uma subdivisão da divisão fiscal.	Categórico	73.779	46					10	
Nº Quarteirão	Subdivisão do setor. Em um determinado setor há vários quarteirões.	Categórico	73.779	278					33	
CEP	Código criado pelos Correios para identificar uma determinada localização.	Categórico	73.779	2.150					91240001	
Nº do endereço	Nº do endereço do imóvel situado numa determinada rua, avenida ou logradouro.	Categórico	73.779	2.651					50	
Metragem área testada	Comprimento da frente do terreno, em metros	Numérico	73.779	1.501	1,1	686,85	37,74	20,2	11	49,9
Metragem área real	Área real cadastrada do imóvel, em m²	Numérico	73.779	13.327	0,90	1.016,54	49,01	38,69	69,97	40,14
Metragem área construída	Área construída total, em m²	Numérico	73.779	7.751	3,00	2.680,80	118,31	89,00	56,00	96,19
Metragem área corrigida	É a área utilizada pela Prefeitura para o cálculo do valor venal do imóvel e do IPTU, em m²	Numérico	73.779	369	1,00	818,00	44,95	35,00	22,00	37,49
Valor venal do terreno	O valor venal do terreno é o valor atribuído pela Prefeitura ao terreno onde se situa o imóvel, para fins tributários.	Numérico	73.779	48.221	1.400,07	2.685.903,00	88.676,20	56.031,48	49.328,79	109.879,27
Valor venal das construções	Valor estimado pela Prefeitura para as construções existentes no imóvel.	Numérico	73.779	20.260	2.326,08	19.738.253,60	268.761,45	124.815,90	69.732,00	423.075,33
Valor venal do imóvel	Valor venal total do imóvel. Valor avaliado pela Prefeitura.	Numérico	73.779	60.982	6.042,00	22.054.258,01	357.437,65	197.308,29	154.167,23	502.877,22
Valor da alíquota	Percentual aplicado à base de cálculo do IPTU para determinar o imposto.	Numérico	73.779	9	0,00	0,85	0,43	0,47	0,47	0,19
Valor da Taxa de Coleta de Lixo	Valor da Taxa de Coleta de Lixo, cobrada pelo serviço público de coleta e destinação dos resíduos.	Numérico	73.779	49	0,00	6.850,18	395,32	340,49	340,49	239,02
Valor do imposto (coluna alvo)	Valor do Imposto Territorial e Predial Urbano para determinado imóvel.	Numérico	73.779	47.630	0,00	180.848,27	1.403,99	433,38	0,00	3.241,50